


# 深度神经网络

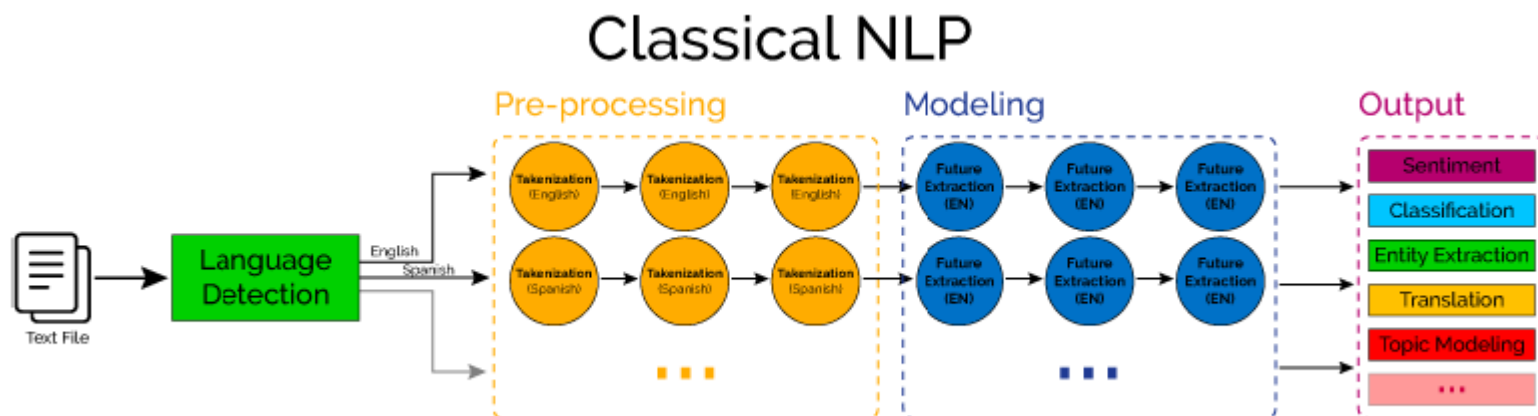
---

# 深度神经网络


## Fully Connect Feedforward Network



# 深度学习与传统机器学习



无需专门的特征选择

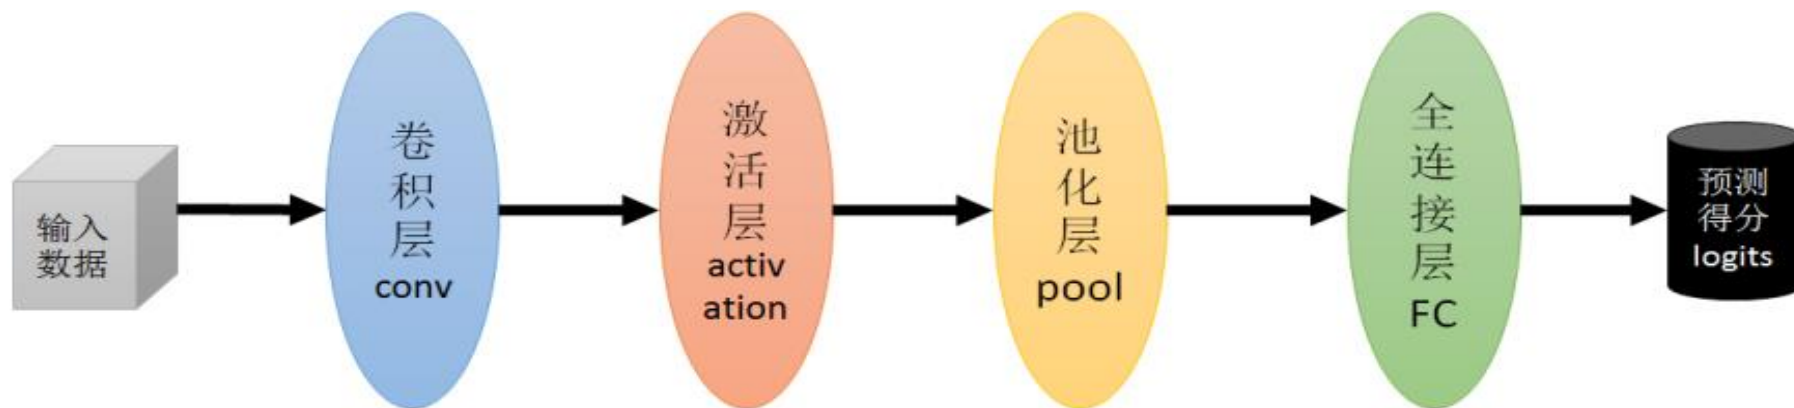


# 卷积神经网络分析

## 一个简单的卷积神经网络

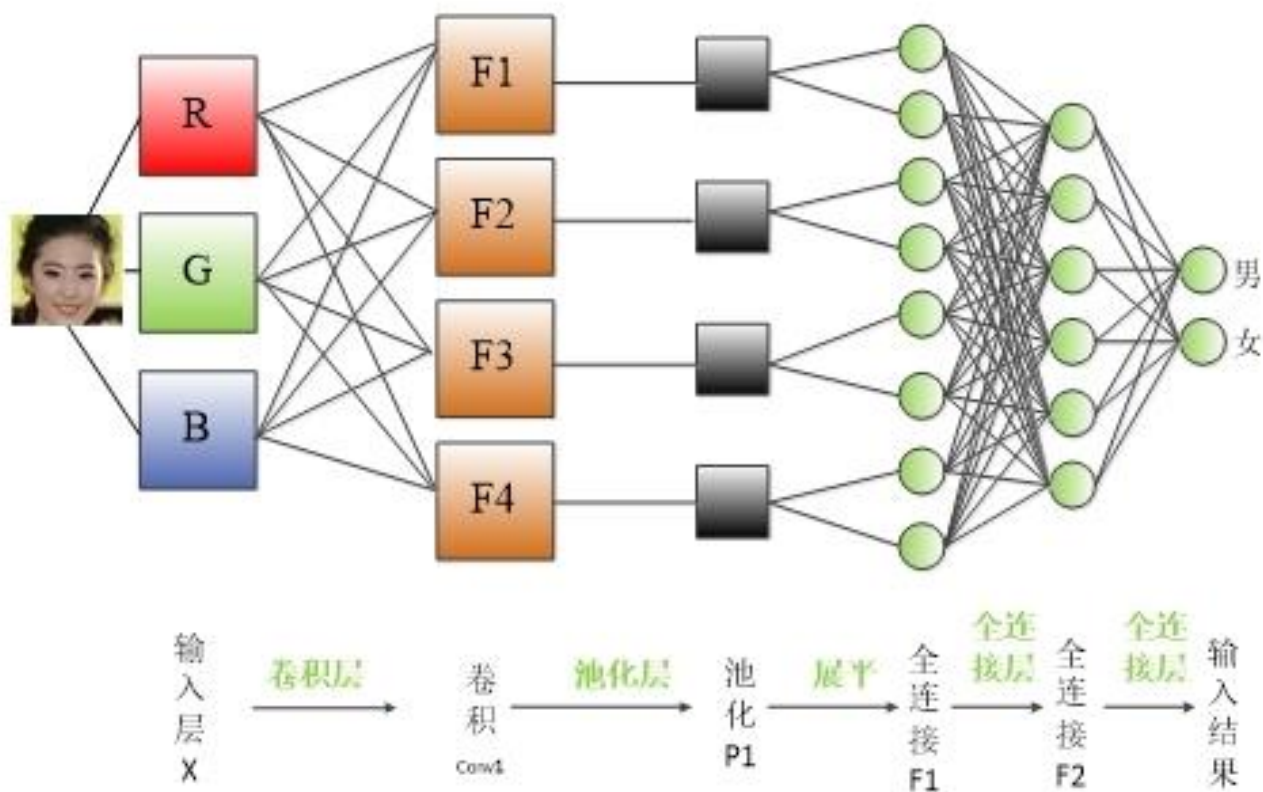
构成：

- 数据输入层
  - 激活层
  - 全连接层
- 卷积层  
池化层



# 卷积神经网络分析

## 一个简单的卷积神经网络





# 卷积神经网络分析

---

## □卷积层

- 卷积层是卷积神经网络的**核心**模块。
- 作用：进行**特征提取(选出最重要的特征)**
- 这里特征提取是**自动**而非通过人工指定的，主要通过**filter（也称卷积核）**在模式（如图像）上平移来提取。就好比人观察图片，通过上下扫描图片，提取想要的信息。



# 卷积神经网络分析

---

## □ 卷积层

### ➤ 局部感知

人识别图片的过程中，并不是整张图同时识别，而是对于图片中的每一个特征首先局部感知，然后更高层次对局部信息进行综合，从而得到全局信息。

类似于蚂蚁寻食，每个蚂蚁通过局部感知，找到它认为最大个的食物，再通过综合，获得全局最大食物。

# 卷积神经网络分析

## □ 卷积层

➤ 通过卷积运算得到特征图

1 <sub>x1</sub>	1 <sub>x0</sub>	1 <sub>x1</sub>	0	0
0 <sub>x0</sub>	1 <sub>x1</sub>	1 <sub>x0</sub>	1	0
0 <sub>x1</sub>	0 <sub>x0</sub>	1 <sub>x1</sub>	1	1
0	0	1	1	0
0	1	1	0	0

Image


1 0 1  
0 1 0 卷积核  
1 0 1

4		

Convolved  
Feature

特征图

$$1*1 + 1*0 + 1*1 + 0*0 + 1*1 + 1*0 + 0*1 + 0*0 + 1*1 = 4$$



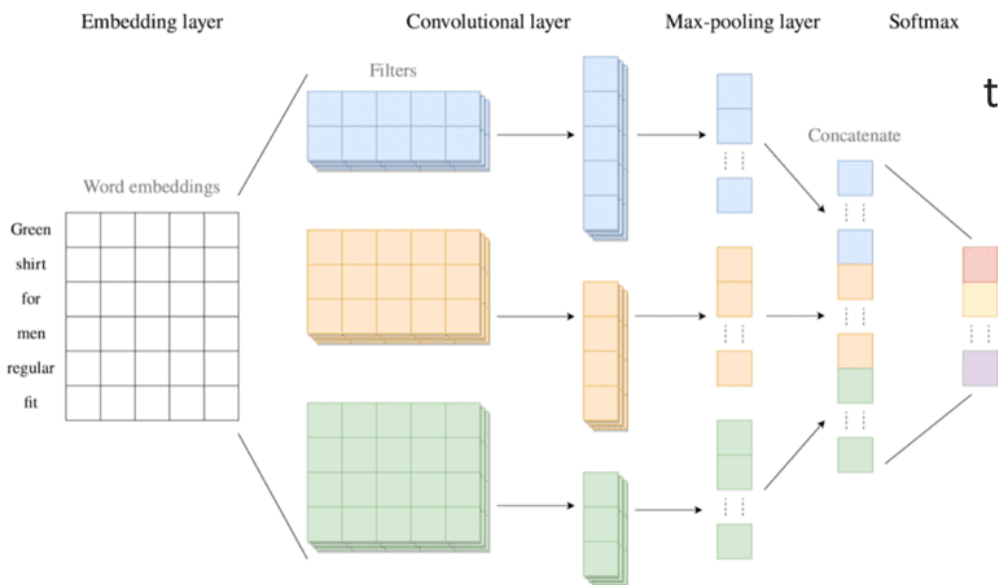

把每次移动的距离称为步幅s



# 卷积神经网络分析

## □ 卷积层

➤ NLP中的卷积示意



text cnn中的多卷积核

# 卷积神经网络分析

## □ 卷积层

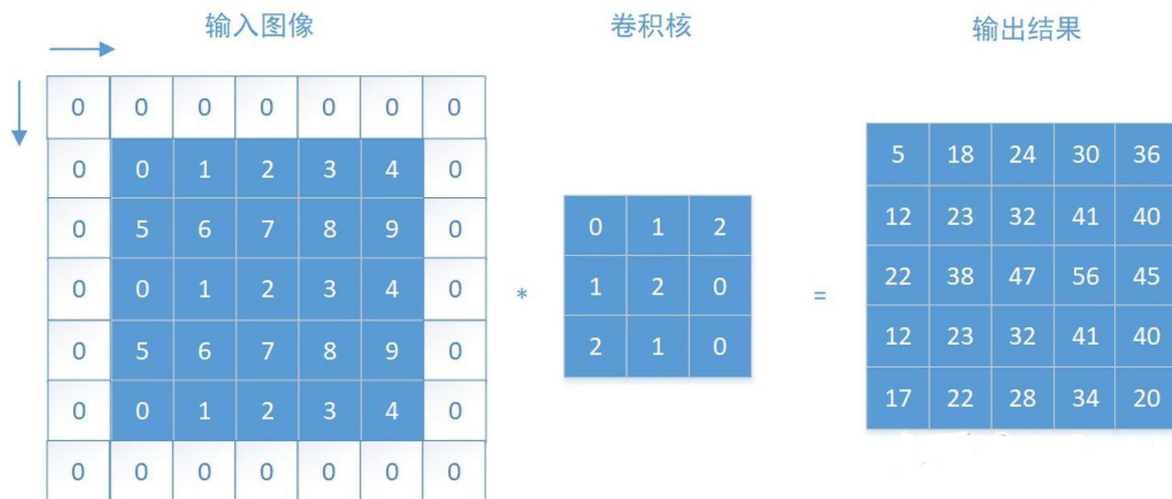
### ➤ 填充padding

在输入矩阵周围填充0。

### ➤ 目的

保持边界信息

使得输入输出图像尺寸一致




# 卷积神经网络分析

## □ 卷积层

Edge Detection

Using Kernel Convolution



# 卷积神经网络分析

## □ 卷积层



1	2	1
0	0	0
-1	-2	-1




1	0	-1
0	0	0
-1	0	1

# 卷积神经网络分析

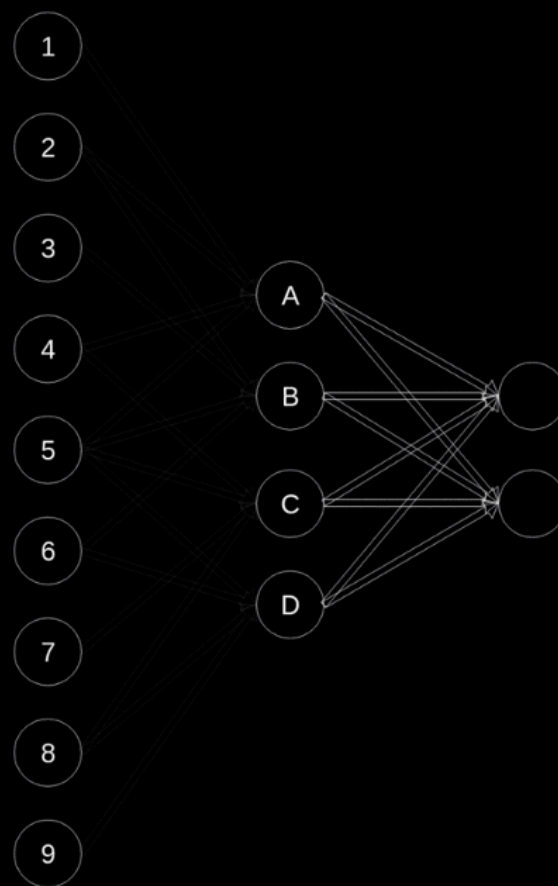

与全连接层相比，卷积层的两个主要优势：

- (1) 参数共享：卷积核在数据上移动 使用相同的权值向量来做卷积
- (2) 稀疏连接：卷积核仅与数据中的某些个部分连接



# 卷积神经网络分析

## Connection Cutting Parameters Shering





# 卷积神经网络分析

---

## □ 激活层

激活层一般紧接在卷积层后，是对卷积层的输出结果做一次非线性映射。

如果不用激活函数，每一层的输出都只是上一层输入的线性函数。

常用的激励函数有：

- (1) Sigmoid函数
- (2) Tanh函数
- (3) ReLU


# 卷积神经网络分析

## □ 激活层

Sigmoid函数

Tanh函数

ReLU



Input

-249	-91	-37
250	-134	101
27	61	-153

ReLU

0	0	0
250	0	101
27	61	0




# 卷积神经网络分析

## □池化层

- 主要用于特征降维，压缩数据和参数的数量，减小过拟合，同时提高模型的容错性。主要有：

Max Pooling: 最大池化, 选取最大值

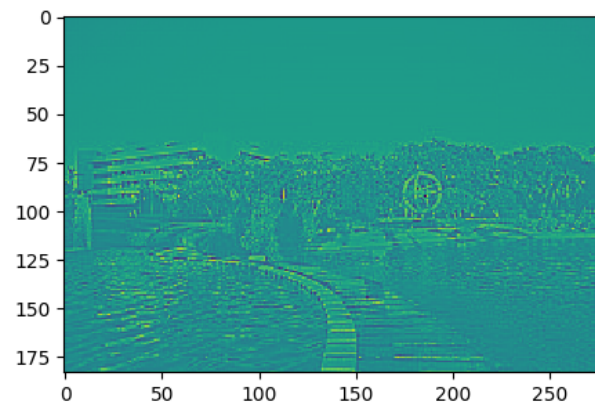

Average Pooling: 平均池化，选取平均值




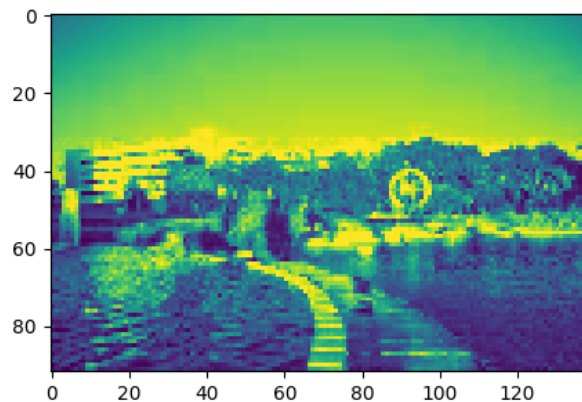
# 卷积神经网络分析

## □池化层

卷积和池化效果



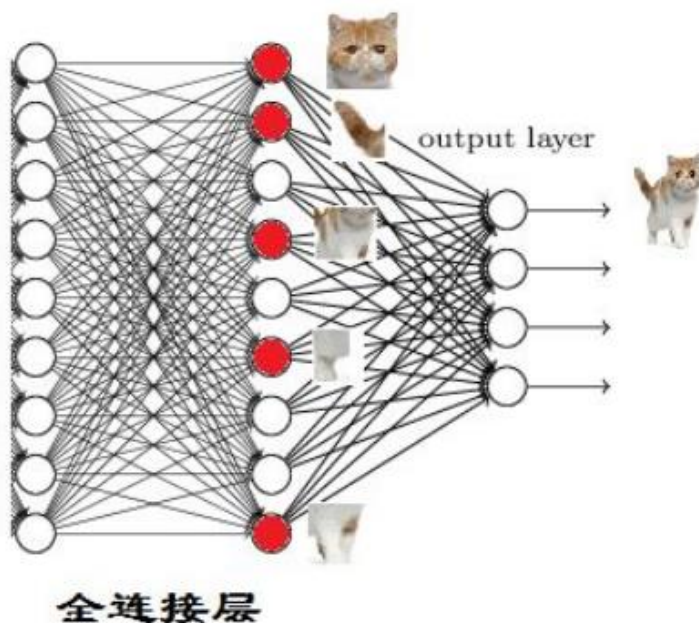
<http://blog.csdn.net/fendouaini>



# 卷积神经网络分析

## □ 全连接层

全连接层的每一个结点都与上一层的所有结点相连，作用是把前边提取到的特征综合起来。一般全连接层的参数是最多的。

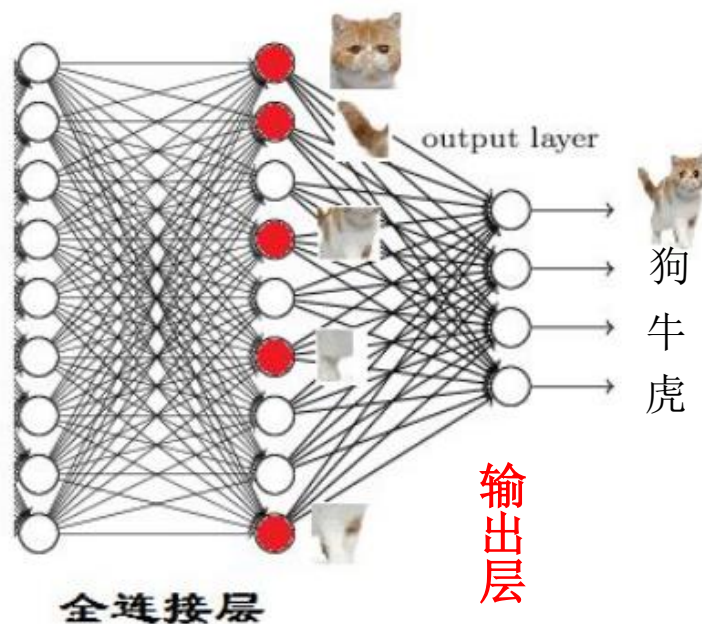


例如VGG16中，第一个全连接层FC1有4096个节点，上一层POOL2是25088个节点，则需要 $4096 \times 25088$ 个权值，需要很大的内存。

# 卷积神经网络分析

## 模型输出

卷积神经网络的最后一层往往是全连接层+Softmax（分类网络），通过它给每种类别赋予一个概率。





$$\text{softmax}(z_j) = \frac{e^{z_j}}{\sum_K e^{z_j}}$$

# 卷积神经网络分析

## Dropout


Dropout 实际上是一种正则化形式，旨在防止过拟合。对于训练集中的每个batch，dropout 以概率 $p$ 随机断开网络中从前一层到下一层的部分输入。




# 卷积神经网络分析

## Dropout

图中黑色曲线是正常模型，绿色曲线是overfitting模型。尽管绿色曲线精确地区分了训练数据，但是对新数据的适应性较差。



# NLP中的卷积神经网络



- 将卷积神经网络用于文本分类。
- 输入句子对应的词向量矩阵，经过一层卷积层和一层Max Pooling层，得到句向量表示，再送入到全连接层，最后softmax输出。





# NLP中的卷积神经网络

---

## ■ 优点

卷积神经网络擅长提取重要的局部特征。

在文本分类中，可以理解为不同大小的卷积核在提取不同n-gram特征。

## ■ 缺点

卷积神经网络无法考虑长距离的依赖信息，且没有考虑词序信息，在有限的窗口下提取句子特征，会损失一些语义信息。





# 卷积神经网络实现

[Keras 中文文档](https://keras-zh.readthedocs.io/): <https://keras-zh.readthedocs.io/>

```
from keras.models import Sequential
from keras.layers import Dense, Activation
from keras.optimizers import SGD
```

```
model = Sequential()
model.add(Dense(output_dim=64, input_dim=100))
model.add(Activation("relu"))
model.add(Dense(output_dim=10))
model.add(Activation("softmax"))
```

```
model.compile(loss='categorical_crossentropy',
              optimizer='sgd', metrics=['accuracy'])
```

```
model.fit(X_train, Y_train, nb_epoch=5, batch_size=32)
```

```
loss = model.evaluate(X_test, Y_test, batch_size=32)
```

加入全连接层，将dense  
换成Conv1D可加入卷积  
层，换成MaxPooling1D  
可加入池化层

加入全连接层2

指定模型设置：如使用交叉熵和随机梯度下降优化器

赋予模型训练数据，循环  
训练5轮，每轮将数据分  
为大小32的子集



# 循环神经网络RNN

---


- 动机：很多任务需要处理序列关系。比如，当在理解一句话的意思时，孤立地理解这句话的每个词是不够的，需要处理这些词连接起来的整个序列；
- 时序预测问题（timeseries），诸如预测天气、温度

普通的神经网络假设输入和输入之间是相互独立的。

RNN中不仅每层之间的神经元存在连接，**同一层之间的神经元**也存在连接，**上一个时刻的状态能作用于下一个时刻的状态**。

# RNN模型应用

- 文本分类  
方式1: 使用最后的隐变量作为句向量



数据

挖掘



# 基于Keras实现LSTM

```
max_features = 20000      #max_features给出了最多使用的单词数
batch_size = 32
(x_train, y_train), (x_test, y_test) = imdb.load_data(path='./imdb.npz', num_words=max_features)

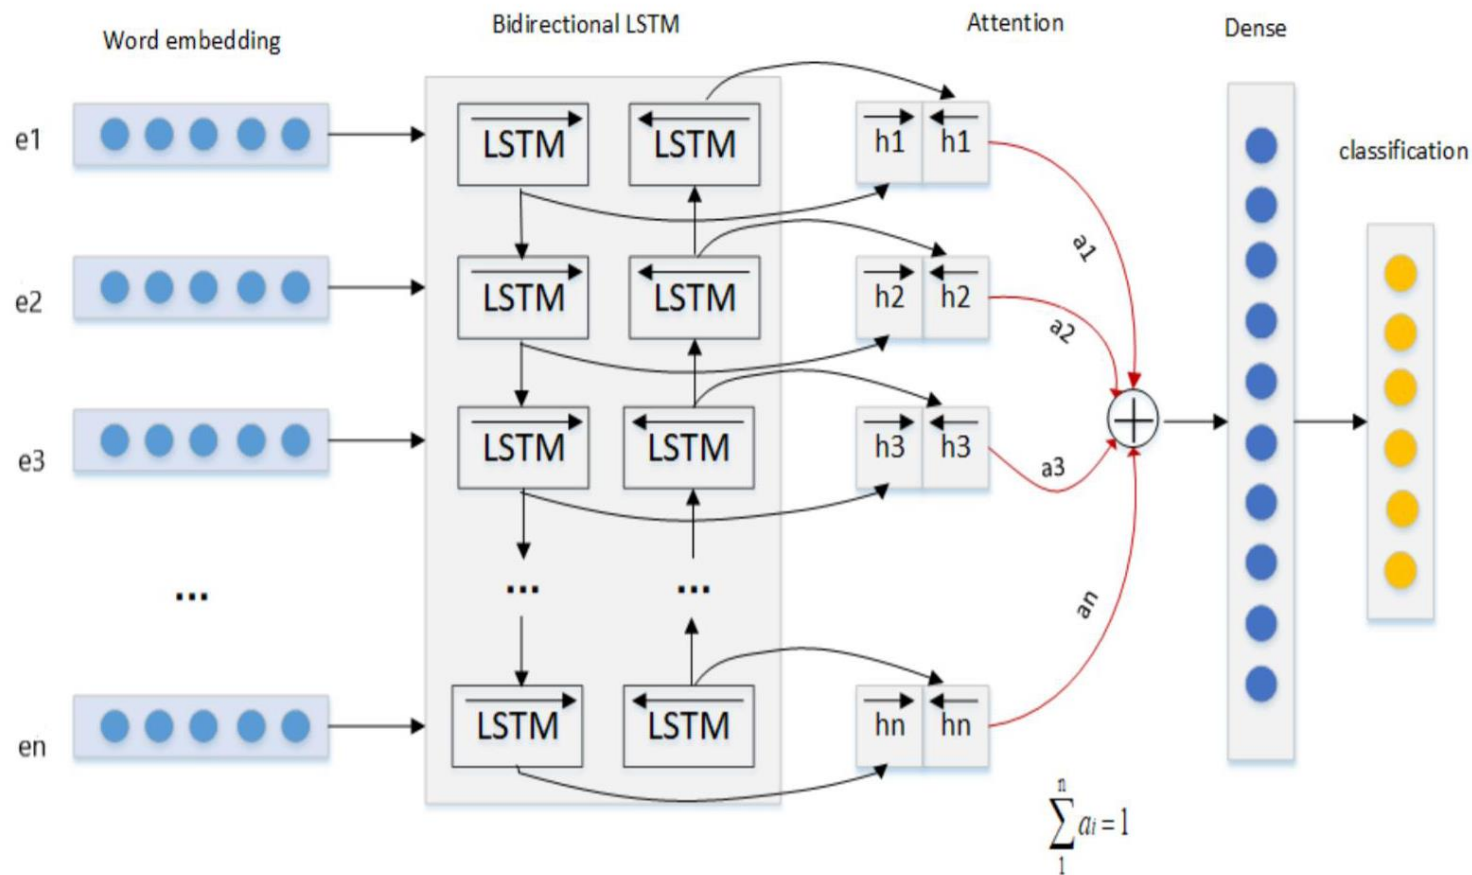
model = Sequential()
model.add(Embedding(max_features, 128))
model.add(LSTM(128, dropout=0.2, return_sequences=False, recurrent_dropout=0.2)) #输出层的维
度128，即每个门的输出。 return_sequences=True表示返回每个时间片的隐状态，false返回最后
时刻的隐状态。
model.add(Dense(1, activation='sigmoid'))      #1个输出，二分类，如果多分类用softmax

model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy']) #使用Adam优化
器

model.fit(x_train, y_train, batch_size=batch_size, epochs=15)
score, acc = model.evaluate(x_test, y_test, batch_size=batch_size)
```

# RNN模型应用

- 文本分类      方式2: 使用每个词的隐变量拼成句向量





# RNN模型应用

---

- 双向LSTM实现

```
model = Sequential()  
model.add(Bidirectional(LSTM(10)))  
model.add(Dense(5))  
model.add(Activation('softmax'))  
model.compile(loss='categorical_crossentropy', optimizer='rmsprop')
```


```
keras.layers.Bidirectional(layer, merge_mode='concat', weights=None)
```

**merge\_mode**: 前向和后向 RNN 的输出的结合模式。为 {'sum', 'mul', 'concat', 'ave', None} 其中之一。


# RNN模型应用

- 神经网络机器翻译

翻译器由**编码器**和**解码器**构成：



## Neural Machine Translation SEQUENCE TO SEQUENCE MODEL



Je

suis

étudiant

# RNN模型应用

- 神经网络机器翻译

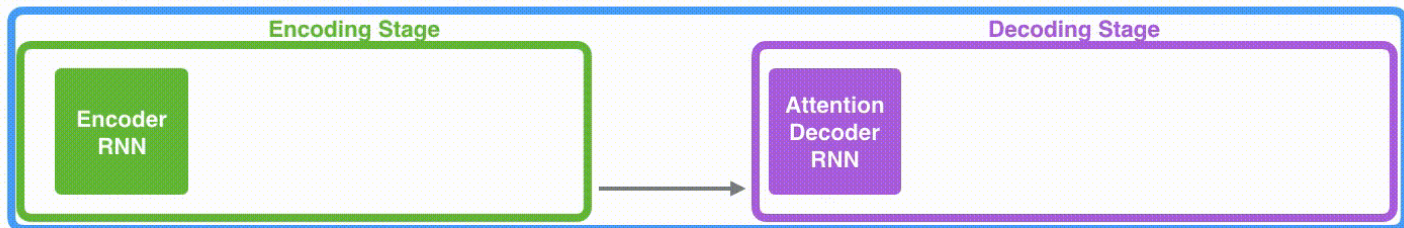
编码器-解码器结构有两个缺陷：

- (1) 编码器需将所有输入压缩成固定长度的向量，造成输入信息的丢失。
- (2) 不能对输入序列和输出序列的(位置)对应关系进行建模。

解决方法：引入注意力机制。

## Neural Machine Translation

SEQUENCE TO SEQUENCE MODEL WITH ATTENTION



Je

suis

étudiant



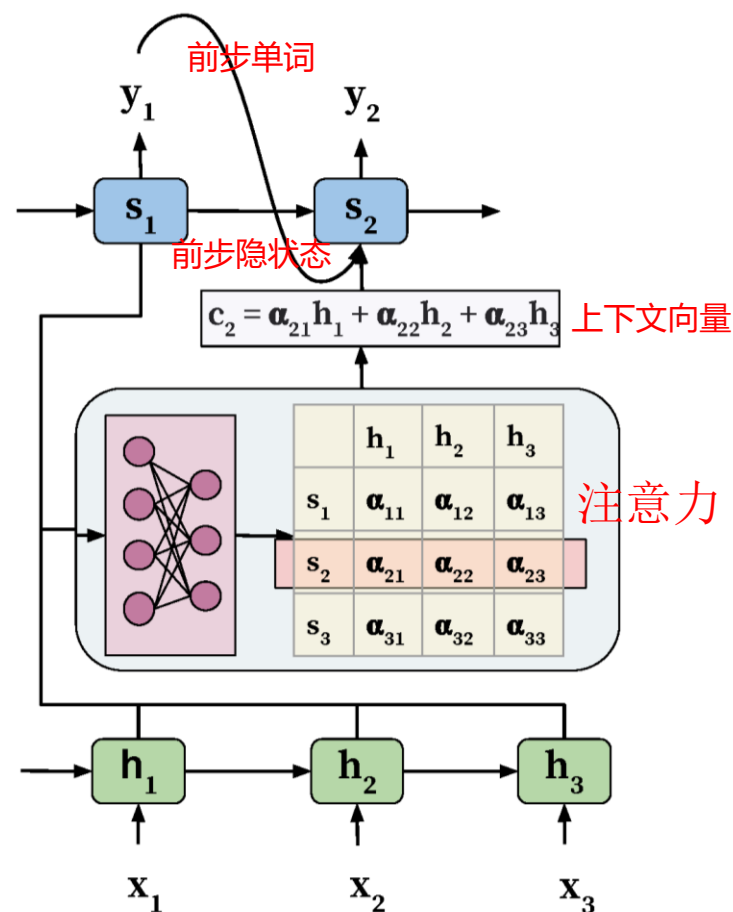
# RNN模型应用

- 神经网络机器翻译

利用注意力改进：

(1) 编码器不只传递编码阶段的最后一个隐藏状态，而是将所有隐藏状态传递给解码器：

(2) 解码器计算当前隐状态与编码器传入的每个隐状态的相关性，产生注意力权值；



# 主流深度学习框架

目前最主流的是TensorFlow

华为的AI计算框架：  
MindSpore

Microsoft  
CNTK

Caffe

Caffe2



PYTORCH

Chainer

K Keras

TensorFlow

theano

dy/net

mxnet

GLUON

常见的深度学习框架



---

# Thanks

谢谢!